05 Y 06. Anonimización y Análisis del riesgo de reidentificación

Alumno: Cesar Alberto Lopez Zavala. Fecha: 18-10-2026.

Preguntas y respuestas

¿Qué identificadores directos fueron eliminados?

Fueron eliminados por completo el nombre, correo, telefono, rfc y el id interno. Ninguno de estos campos aparece en la consulta de resultados estadísticos entregada al área de dirección.

¿Qué cuasi-identificadores permanecen?

Permanecen la edad y el codigo_postal (la ubicación geográfica), aunque ya no están en su formato exacto, sino que se mantuvieron transformados para generar la estadística.

¿Qué combinaciones de atributos podrían reducir el anonimato?

La combinación de un rango de edad específico con una región geográfica muy acotada. Por ejemplo, si en un grupo solo hay dos personas que caen en el rango "46+" dentro de una región postal particular, y un atacante cruza esa información con un padrón público, podría deducir quiénes son esas personas. A esto se le conoce como el "efecto mosaico".

¿Qué sucede cuando un grupo contiene pocos registros?

El riesgo de reidentificación aumenta drásticamente, perdiendo lo que en seguridad se conoce como k-anonimato. Si un grupo estadístico tiene 1 o 2 personas, cualquier conocimiento externo sobre esa persona permite ligarla directamente a ese registro. Por eso se implementó el filtro HAVING COUNT(*) >= 5, para asegurar que un individuo siempre se "esconda" entre al menos otras 4 personas.

¿Qué atributos deberían generalizarse?

Los cuasi-identificadores. Como se hizo en la práctica, la edad exacta (ej. 35) se generalizó convirtiéndola en rangos (ej. '31-45'). El codigo_postal exacto (ej. 80000) se generalizó recortándolo a los primeros 2 dígitos para representar una región más amplia en lugar de una colonia específica.

¿Qué información debería suprimirse?

El riesgo de reidentificación aumenta drásticamente, perdiendo lo que en seguridad se conoce como k-anonimato. Si un grupo estadístico tiene 1 o 2 personas, cualquier conocimiento externo sobre esa persona permite ligarla directamente a ese registro. Por eso se implementó el filtro HAVING COUNT(*) >= 5, para asegurar que un individuo siempre se "esconda" entre al menos otras 4 personas.

¿Es correcto afirmar que el conjunto de datos es “100 % anónimo”? ¿Por qué?

No, nunca es correcto. En seguridad de la información se reconoce que no existe la anonimización absoluta (100 %) a menos que se destruya totalmente la utilidad de los datos. Siempre existe un riesgo residual de reidentificación si en el futuro aparece una nueva fuente de datos pública con la cual cruzar estos cuasi-identificadores. La anonimización no es un estado absoluto, sino un proceso de reducción de riesgos hasta un nivel aceptable según el contexto.

Evidencia de ejecución

Captura de la creación, carga y consulta inicial de `clientes`. Se muestran cinco filas.

LAB1/postgres@PostgreSQL

No limit

Query | Query History

```sql
-- 1. Generalización de Edad y Región (Código Postal)
SELECT
    CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
        WHEN edad BETWEEN 31 AND 45 THEN '31-45'
        ELSE '46+'
    END AS rango_edad,
    LEFT(codigo_postal, 2) AS region,
    COUNT(*) AS total
FROM clientes
GROUP BY 1, 2;

-- 2. Supresión de grupos pequeños (k=5)
-- Esta es la consulta principal para Dirección.
SELECT
    CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
```

Data Output | Messages | Notifications

SQL

	rango_edad text	region text	total bigint
1	31-45	81	1
2	46+	82	1
3	31-45	80	3

```sql
-- Esta es la consulta principal para Dirección.
SELECT
    CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
        WHEN edad BETWEEN 31 AND 45 THEN '31-45'
        ELSE '46+'
    END AS rango_edad,
    LEFT(codigo_postal, 2) AS region,
    COUNT(*) AS total
FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;

-- ========================================
-- RETO DE LA ACTIVIDAD 6
```

Data Output | Messages | Notifications

rango_edad text	region text	total bigint

```sql
-- ========================================
-- RETO DE LA ACTIVIDAD 6
-- ========================================
-- Propósito: Reducir aún más el riesgo de reidentificación supri
-- la región si no aporta valor estratégico y generalizando más l
SELECT
    CASE
        WHEN edad < 35 THEN 'Jóvenes (< 35)'
        ELSE 'Adultos (35+)'
    END AS grupo_edad_amplio,
    'Sinaloa' AS estado_general,
    COUNT(*) AS total
FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
```

Data Output | Messages | Notifications

grupo_edad_amplio text	estado_general text	total bigint